

SY09 - Sciences des Données

Identification des profils à risque de décrochage en mathématiques

Mathéo Gros | Maël Lozac'h | Mathieu Piekarz

Université de Technologie de Compiègne ■ SY09 Sciences des Données ■ P26

G. Govaert | T. Denœux | B. Quost | S. Rousseau

Contexte : un écart statistiquement significatif

Données : UCI Student Dataset

- 395 élèves de lycée portugais
- Variables socio-familiales et comportementales disponibles *avant les résultats finaux*
- Deux matières : mathématiques & portugais

Définition : Décrocheur

$$\delta_i = 1 \left[(G_3 = 0) \cap (G_1 > 0) \right]$$


Signal de départ *en cours d'année* (distinct de l'absence initiale).

Asymétrie observée

	Maths	Portugais
Taux décrochage	9,6 %	2,3 %
Effectif	38	13

Signal propre aux mathématiques.

Trajectoires scolaires individuelles — décrocheurs mis en évidence



Dans quelle mesure les variables socio-comportementales disponibles en début d'année permettent-elles d'identifier les profils d'élèves susceptibles de décrocher en mathématiques ?


8 variables retenues ($\alpha = 0,10$)

Numériques Catégorielles

failures	higher
Medu	paid
age	schoolsup
Walc	romantic

Tests : Mann-Whitney (num.) · χ^2 (cat.)

Exclusion absences : paradoxe : les décrocheurs ont 0 absence enregistrée (artefact post-départ).



Distance de Gower : variables hétérogènes

Pour p variables, entre individus i et j :

$$d_{ij} = \frac{1}{p} \sum_{k=1}^p \delta_{ij}^{(k)}$$

- Ordinale : $\delta_{ij}^{(k)} = |x_i^{(k)} - x_j^{(k)}| / r_k$
- Binaire : $\delta_{ij}^{(k)} = \mathbf{1}[x_i^{(k)} \neq x_j^{(k)}]$

↪ Euclidienne inadaptée aux variables mixtes num./cat.


AFTD : Analyse Factorielle des Distances


Double centrage de Δ^2 :

$$W = -\frac{1}{2} Q_n \Delta^2 Q_n, \quad Q_n = I_n - \frac{\mathbf{1}\mathbf{1}^T}{n}$$

Décomposition spectrale $W = U \Lambda U^T \Rightarrow$ coordonnées
 $C = U_+ \Lambda_+^{1/2}$

↪ L'ACP requiert des variables brutes ; l'AFTD opère directement sur Δ .





Convergence CAH-Ward / K-means


$ARI = 0,98 \Rightarrow$ **partitions très similaires**
Résultat robuste, indépendant de la méthode.
 $K = 4$ choisi par la méthode de la silhouette.

Profil	n	$\hat{\tau}$
C0 : paid, aspirations élevées	61	8,2 %
C1 : sans paid, échecs++	71	21,1 %
C2 : paid, très stable	120	2,5 %
C3 : sans paid, profil moyen	143	10,5 %
Globale	395	9,6 %


C1 = $2,2 \times$ la moyenne · **C2** = profil protecteur

Phase A — Lien cluster ↔ décrochage

Taux de décrochage par cluster
 $\chi^2=18.08$, $p=0.0004$, $V=0.214$



Répartition des 38 décrocheurs entre les 4 clusters



Phase A : Lien cluster ↔ décrochage

$\chi^2 = 18,1$ | $p < 0,001$ | $V_{\text{Cramér}} = 0,214$
Structure non supervisée → signal statistique réel.

Phase B : AUC-ROC (CV 5-fold)

Param. (LDA, LogReg) vs non-param. (CART, LightGBM).

Classifieur	AUC	Boot. 632
LDA (Ch.10)	0,746	11,1 %
LogReg (Ch.11)	0,747	28,9 %
CART (Ch.12)	0,632	25,1 %
LightGBM (Ch.12)	0,702	21,3 %

`class_weight='balanced'` : déséquilibre 1 :10 — sans correction, l'accuracy atteint 90 % en prédisant systématiquement « non »

Estimateurs : resubst. · holdout · CV-5 · **boot.632**

Limite fondamentale

AUC > 0,5 : discrimination réelle au-delà de l'aléatoire.
Prédiction individuelle limitée ($n_{\text{décocheurs}} = 38$).



Règle de Neyman-Pearson, triangulation et conclusion

Neyman-Pearson sur LogReg

Maximiser le rappel sous $FPR \leq \alpha^* = 0,20$:

$$s^* = \arg \max_{s : FPR(s) \leq 0,20} TPR(s)$$

Coût asymétrique : manquer un décrocheur $\gg$ fausse alarme.



Convergence : 4 méthodes indépendantes

failures #1 NB01 & CART : signal dominant
Medu #2 NB01 : contexte familial
Walc #2 LightGBM : facteur comport.

Signal robuste et non-artificiel.

Recommandation opérationnelle

$failures \geq 1 + paid = non + Medu \leq 2 + Walc \geq 3$
 $\Rightarrow$ C1 identifiable avant fin d'année (71 / 395 élèves)